RiemannFM 数学形式化

RiemannFM: Geometry- and Text-Aware Flow Matching on Product Manifolds with Joint Continuous-Discrete Dynamics for Knowledge Graph Generation —完整数学定义

目录

- RiemannFM 数学形式化
  - 目录
  - 1. 基础集合与索引约定
  - 2. 子图的形式化定义
  - 3. 子图的矩阵表示
    - 3.1 嵌入空间：乘积流形
    - 3.2 节点坐标
    - 3.3 边类型张量
    - 3.4 文本条件
    - 3.5 虚节点填充
    - 3.6 训练样本与数据集
  - 4. 流形上的基本运算
    - 4.1 测地距离
    - 4.2 切空间
    - 4.3 对数映射
    - 4.4 指数映射
    - 4.5 切空间黎曼范数
  - 5. 模型架构：RieFormer
    - 5.1 总体定义
    - 5.2 输入编码层
    - 5.3 RieFormer 块
      - 5.3.1 子模块 A：流形感知多头注意力
      - 5.3.1 子模块 A：流形感知多头注意力
      - 5.3.3 子模块 C：边流自更新
      - 5.3.4 子模块 D：双向交叉交互
      - 5.3.5 子模块 E：文本条件注入
    - 5.4 输出投影层
      - 5.4.1 向量场输出头
      - 5.4.2 边类型输出头
    - 5.5 排列等变性
  - 6. 离散-连续联合流匹配
    - 6.1 噪声先验分布
    - 6.2 前向插值过程
    - 6.3 条件目标
    - 6.4 训练损失函数
    - 6.5 训练与推理算法

- 7. 下游任务微调
  - 7.1 统一掩码框架
  - 7.2 任务一：知识图谱补全
  - 7.3 任务二：文本条件子图生成
  - 7.4 任务三：图异常检测
- 符号速查表
  - 基础集合与索引
  - 流形与几何
  - 子图表示
  - 模型架构（RieFormer）
  - 流匹配
  - 损失函数
  - 下游任务

---

1. 基础集合与索引约定

定义 1.1（基础集合）。

- **实体集**：$\mathcal{V} = \{v_1, v_2, \ldots, v_{|\mathcal{V}|}\}$。
- **关系类型集**：$\mathcal{R} = \{r_1, r_2, \ldots, r_K\}$，$K \triangleq |\mathcal{R}|$。
- **知识图谱**：$\mathcal{K} = (\mathcal{V}, \mathcal{E})$，其中事实集 $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{R} \times \mathcal{V}$。一个事实 $(v_i, r_k, v_j) \in \mathcal{E}$ 表示实体 v_i 通过关系 r_k 有向地连接到实体 v_j。

自环：允许 $i = j$，即 $(v_i, r_k, v_i) \in \mathcal{E}$ 合法。

多关系边：同一有序实体对 (v_i, v_j) 可关联多种关系类型，即可同时存在 $(v_i, r_a, v_j) \in \mathcal{E}$ 和 $(v_i, r_b, v_j) \in \mathcal{E}$，$a \neq b$。

相反关系：语义相反的关系（如"父亲"与"子女"）作为 $\mathcal{R}$ 中独立的元素存在，不人工添加反向关系。

---

2. 子图的形式化定义

记号：对任意正整数 n，记 $[n] \triangleq \{1, 2, \ldots, n\}$。

定义 2.1（子图）。子图 $\mathcal{G} = (\mathcal{V}_\mathcal{G}, \mathcal{E}_\mathcal{G})$ 是 $\mathcal{K}$ 的诱导子图：- $\mathcal{V}_\mathcal{G} \subseteq \mathcal{V}$，$|\mathcal{V}_\mathcal{G}| = N$；- $\mathcal{E}_\mathcal{G} = \{(v_i, r_k, v_j) \in \mathcal{E} \mid v_i, v_j \in \mathcal{V}_\mathcal{G}\}$。

对 $\mathcal{V}_\mathcal{G}$ 中的节点重新编号为 $[N]$。后续 $i, j \in [N]$ 均指子图内的局部编号。

---

3. 子图的矩阵表示

子图 $\mathcal{G}$ 编码为五元组 $(\mathbf{X}, \mathbf{E}, \mathbf{C}_\mathcal{V}, \mathbf{C}_\mathcal{R}, \mathbf{m})$，分别对应节点流形坐标、边类型张量、节点文本条件矩阵、关系文本条件矩阵和节点掩码。各分量在以下小节中依次

定义。

3.1 嵌入空间：乘积流形

定义 3.1（Lorentz 内积）。对 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^{d_h+1}$：

$$\langle \mathbf{a}, \mathbf{b} \rangle_{\mathrm{L}} = -a_0 b_0 + \sum_{l=1}^{d_h} a_l b_l$$

定义 3.2（乘积流形）。

$$\mathcal{M} = \mathbb{H}_{\kappa_h}^{d_h} \times \mathbb{S}_{\kappa_s}^{d_s} \times \mathbb{R}^{d_e}$$

其中：- $\mathbb{H}_{\kappa_h}^{d_h} = \{\mathbf{z} \in \mathbb{R}^{d_h+1} \mid \langle \mathbf{z}, \mathbf{z} \rangle_{\mathrm{L}} = 1/\kappa_h,\ z_0 > 0\}$，$d_h$ 维双曲空间（Lorentz 模型），曲率 $\kappa_h < 0$；- $\mathbb{S}_{\kappa_s}^{d_s} = \{\mathbf{z} \in \mathbb{R}^{d_s+1} \mid \|\mathbf{z}\|_2^2 = 1/\kappa_s\}$，$d_s$ 维球面，曲率 $\kappa_s > 0$；- $\mathbb{R}^{d_e}$ 为 d_e 维欧氏空间。

总环境空间维度 $D \triangleq (d_h + 1) + (d_s + 1) + d_e$。

分量记号：对 $\mathbf{x} \in \mathcal{M}$，记 $\mathbf{x}^{\mathbb{H}} \in \mathbb{R}^{d_h+1}$，$\mathbf{x}^{\mathbb{S}} \in \mathbb{R}^{d_s+1}$，$\mathbf{x}^{\mathbb{R}} \in \mathbb{R}^{d_e}$ 为三个子空间分量。

3.2 节点坐标

定义 3.3（节点坐标）。

$$\mathbf{X} = (\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_N) \in \mathcal{M}^N$$

其中 $\mathbf{x}_i = (\mathbf{x}_i^{\mathbb{H}}, \mathbf{x}_i^{\mathbb{S}}, \mathbf{x}_i^{\mathbb{R}}) \in \mathcal{M}$，$i \in [N]$。

3.3 边类型张量

定义 3.4（边类型张量）。

$$\mathbf{E} \in \{0,1\}^{N \times N \times K}$$

$$\mathbf{E}_{ij}^{(k)} = \mathbb{1}[(v_i, r_k, v_j) \in \mathcal{E}_{\mathcal{G}}]$$

固定 (i, j) 时，$\mathbf{E}_{ij} \in \{0,1\}^K$ 为多热向量：$\mathbf{E}_{ij} = \mathbf{0}_K$ 表示 i 到 j 无边，$\|\mathbf{E}_{ij}\|_1 \in \{0, 1, \ldots, K\}$ 表示 i 到 j 的关系类型数。

性质：- **非对称**：一般地 $\mathbf{E}_{ij} \neq \mathbf{E}_{ji}$；- **多重性**：$\|\mathbf{E}_{ij}\|_1$ 可大于 1。- **稀疏性**：平均出度 $\bar{d} = \frac{1}{N} \sum_{i=1}^{N} |\{j \in [N] : \mathbf{E}_{ij} \neq \mathbf{0}_K\}| \ll N$。

3.4 文本条件

记号：设 Σ 为字符表，Σ^* 为 Σ 上的有限字符串集，$\circ$ 为字符串拼接运算。

定义 3.5（文本条件向量）。设 $\phi_{\text{text}} : \Sigma^* \to \mathbb{R}^{d_c}$ 为预训练文本编码器。对每个节点 v_i：

$$\mathbf{c}_{v_i} = \phi_{\text{text}}(\text{label}_{v_i} \circ \text{desc}_{v_i}) \in \mathbb{R}^{d_c}$$

对每个关系类型 r_k：

$$\mathbf{c}_{r_k} = \phi_{\text{text}}(\text{label}_{r_k} \circ \text{desc}_{r_k}) \in \mathbb{R}^{d_c}$$

后续简记 $\mathbf{c}_i \triangleq \mathbf{c}_{v_i}$。

定义 3.6（文本条件矩阵）。- 节点文本矩阵：$\mathbf{C}_{\mathcal{V}} = (\mathbf{c}_1, \ldots, \mathbf{c}_N) \in \mathbb{R}^{N \times d_c}$（子图级）；- 关系文本矩阵：$\mathbf{C}_{\mathcal{R}} = (\mathbf{c}_{r_1}, \ldots, \mathbf{c}_{r_K}) \in \mathbb{R}^{K \times d_c}$（全局，所有子图共享）。

3.5 虚节点填充

定义 3.7（虚节点填充）。设 $N_{\max} \in \mathbb{Z}_{>0}$ 为子图节点数上界（预设超参数）。对 $|\mathcal{V}_{\mathcal{G}}| \leq N_{\max}$ 的子图，填充 $N_{\max} - |\mathcal{V}_{\mathcal{G}}|$ 个虚节点，使总节点数为 $N_{\max}$：

- 虚节点坐标：$\mathbf{x}_i = \mathbf{x}_{\varnothing} \in \mathcal{M}$，其中锚点各分量为

$$\mathbf{x}_{\varnothing}^{\mathbb{H}} = \left(\frac{1}{\sqrt{|\kappa_h|}}, 0, \ldots, 0 \right) \in \mathbb{R}^{d_h+1}, \quad \mathbf{x}_{\varnothing}^{\mathbb{S}} = \left(\frac{1}{\sqrt{\kappa_s}}, 0, \ldots, 0 \right) \in \mathbb{R}^{d_s+1}, \quad \mathbf{x}_{\varnothing}^{\mathbb{R}} = \mathbf{0}_{d_e}$$

- 虚节点边：$\forall j \in [N_{\max}]$，$\mathbf{E}_{ij} = \mathbf{E}_{ji} = \mathbf{0}_K$；
- 虚节点文本：$\mathbf{c}_i = \mathbf{0}_{d_c}$。

可验证 $\mathbf{x}_{\varnothing}^{\mathbb{H}}$ 满足 $\langle \mathbf{x}_{\varnothing}^{\mathbb{H}}, \mathbf{x}_{\varnothing}^{\mathbb{H}} \rangle_{\mathrm{L}} = -1/|\kappa_h| = 1/\kappa_h$ 且首分量大于零；$\mathbf{x}_{\varnothing}^{\mathbb{S}}$ 满足 $\|\mathbf{x}_{\varnothing}^{\mathbb{S}}\|_2^2 = 1/\kappa_s$。

定义 3.8（节点掩码）。

$$\mathbf{m} \in \{0,1\}^{N_{\max}}, \quad m_i = \begin{cases} 1 & \text{真实节点} \\ 0 & \text{虚节点} \end{cases}$$

满足 $\sum_{i=1}^{N_{\max}} m_i = |\mathcal{V}_{\mathcal{G}}|$。

符号约定：自此以后，$N \triangleq N_{\max}$。后续所有公式中 $i, j \in [N]$ 包含真实节点与虚节点，虚节点通过 $\mathbf{m}$ 识别和屏蔽。

3.6 训练样本与数据集

定义 3.9（训练样本）。一个训练样本即子图的五元组编码：

$$\left(\mathbf{X} \in \mathcal{M}^N,\ \mathbf{E} \in \{0,1\}^{N \times N \times K},\ \mathbf{C}_{\mathcal{V}} \in \mathbb{R}^{N \times d_c},\ \mathbf{C}_{\mathcal{R}} \in \mathbb{R}^{K \times d_c},\ \mathbf{m} \in \{0,1\}^N \right)$$

定义 3.10（训练数据集）。$\mathcal{D} = \{\mathcal{G}_1, \mathcal{G}_2, \ldots, \mathcal{G}_{|\mathcal{D}|}\}$ 为从知识图谱 $\mathcal{K}$ 中采样的子图集合。

---

4. 流形上的基本运算

4.1 测地距离

定义 4.1（分量测地距离）。

- 双曲距离 $d_{\mathbb{H}} : \mathbb{H}^{d_h}_{\kappa_h} \times \mathbb{H}^{d_h}_{\kappa_h} \to \mathbb{R}_{\geq 0}$：

$$d_{\mathbb{H}}(\mathbf{a}, \mathbf{b}) = \frac{1}{\sqrt{|\kappa_h|}} \operatorname{arccosh}(\kappa_h \cdot \langle \mathbf{a}, \mathbf{b} \rangle_{\mathrm{L}})$$

  其中 $\kappa_h \cdot \langle \mathbf{a}, \mathbf{b} \rangle_{\mathrm{L}} \geq 1$ 对所有 $\mathbf{a}, \mathbf{b} \in \mathbb{H}^{d_h}_{\kappa_h}$ 成立。

- 球面距离 $d_{\mathbb{S}} : \mathbb{S}^{d_s}_{\kappa_s} \times \mathbb{S}^{d_s}_{\kappa_s} \to \mathbb{R}_{\geq 0}$：

$$d_{\mathbb{S}}(\mathbf{a}, \mathbf{b}) = \frac{1}{\sqrt{\kappa_s}} \arccos\big(\kappa_s \cdot \mathbf{a}^\top \mathbf{b}\big)$$

  其中 $\kappa_s \cdot \mathbf{a}^\top \mathbf{b} \in [-1, 1]$ 由 Cauchy-Schwarz 不等式保证。

- 欧氏距离 $d_{\mathbb{R}} : \mathbb{R}^{d_e} \times \mathbb{R}^{d_e} \to \mathbb{R}_{\geq 0}$：

$$d_{\mathbb{R}}(\mathbf{a}, \mathbf{b}) = \|\mathbf{a} - \mathbf{b}\|_2$$

定义 4.2（乘积流形测地距离）。 $d_{\mathcal{M}} : \mathcal{M} \times \mathcal{M} \to \mathbb{R}_{\geq 0}$：

$$d_{\mathcal{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{d_{\mathbb{H}}(\mathbf{x}^{\mathbb{H}}, \mathbf{y}^{\mathbb{H}})^2 + d_{\mathbb{S}}(\mathbf{x}^{\mathbb{S}}, \mathbf{y}^{\mathbb{S}})^2 + d_{\mathbb{R}}(\mathbf{x}^{\mathbb{R}}, \mathbf{y}^{\mathbb{R}})^2}$$

$d_{\mathcal{M}}$ 为 $\mathcal{M}$ 上的度量（各分量距离的 ℓ_2 组合保持度量公理）。

4.2 切空间

定义 4.3（切空间）。 对 $\mathbf{x} \in \mathcal{M}$，各分量切空间为：- $T_{\mathbf{x}^{\mathbb{H}}}\mathbb{H} = \{\mathbf{v} \in \mathbb{R}^{d_h+1} \mid \langle \mathbf{v}, \mathbf{x}^{\mathbb{H}} \rangle_{\mathrm{L}} = 0\}$ - $T_{\mathbf{x}^{\mathbb{S}}}\mathbb{S} = \{\mathbf{v} \in \mathbb{R}^{d_s+1} \mid \mathbf{v}^\top \mathbf{x}^{\mathbb{S}} = 0\}$ - $T_{\mathbf{x}^{\mathbb{R}}}\mathbb{R}^{d_e} = \mathbb{R}^{d_e}$

乘积切空间：$T_{\mathbf{x}}\mathcal{M} = T_{\mathbf{x}^{\mathbb{H}}}\mathbb{H} \times T_{\mathbf{x}^{\mathbb{S}}}\mathbb{S} \times \mathbb{R}^{d_e}$。切向量记为 $\mathbf{v} = (\mathbf{v}^{\mathbb{H}}, \mathbf{v}^{\mathbb{S}}, \mathbf{v}^{\mathbb{R}}) \in T_{\mathbf{x}}\mathcal{M}$。

4.3 对数映射

对数映射 $\log_{\mathbf{x}}(\mathbf{y})$ 将流形上的点 $\mathbf{y}$ 拉回到 $\mathbf{x}$ 处的切空间。它回答的问题是："从 $\mathbf{x}$ 出发，沿哪个方向走多远能到达 $\mathbf{y}$？"返回的切向量编码了方向和距离。

定义 4.4（对数映射）。 $\log_{\mathbf{x}} : \mathcal{M} \to T_{\mathbf{x}}\mathcal{M}$，各分量：

- 双曲分量：设 $\mathbf{u} = \mathbf{y}^{\mathbb{H}} - \kappa_h \langle \mathbf{x}^{\mathbb{H}}, \mathbf{y}^{\mathbb{H}} \rangle_{\mathrm{L}} \cdot \mathbf{x}^{\mathbb{H}}$，则

$$\log_{\mathbf{x}^{\mathbb{H}}}(\mathbf{y}^{\mathbb{H}}) = \frac{d_{\mathbb{H}}(\mathbf{x}^{\mathbb{H}}, \mathbf{y}^{\mathbb{H}})}{\|\mathbf{u}\|_{\mathrm{L}}} \cdot \mathbf{u}$$

  其中 $\|\mathbf{u}\|_{\mathrm{L}} = \sqrt{|\langle \mathbf{u}, \mathbf{u} \rangle_{\mathrm{L}}|}$。可验证 $\langle \mathbf{u}, \mathbf{x}^{\mathbb{H}} \rangle_{\mathrm{L}} = 0$，即 $\mathbf{u} \in T_{\mathbf{x}^{\mathbb{H}}}\mathbb{H}$。

- 球面分量：设 $\mathbf{w} = \mathbf{y}^{\mathbb{S}} - \kappa_s(\mathbf{x}^{\mathbb{S}\top}\mathbf{y}^{\mathbb{S}}) \cdot \mathbf{x}^{\mathbb{S}}$，则

$$\log_{\mathbf{x}^{\mathbb{S}}}(\mathbf{y}^{\mathbb{S}}) = \frac{d_{\mathbb{S}}(\mathbf{x}^{\mathbb{S}}, \mathbf{y}^{\mathbb{S}})}{\|\mathbf{w}\|_2} \cdot \mathbf{w}$$

  可验证 $\mathbf{w}^\top \mathbf{x}^{\mathbb{S}} = 0$，即 $\mathbf{w} \in T_{\mathbf{x}^{\mathbb{S}}}\mathbb{S}$。

- 欧氏分量：

$$\log_{\mathbf{x}^{\mathbb{R}}}(\mathbf{y}^{\mathbb{R}}) = \mathbf{y}^{\mathbb{R}} - \mathbf{x}^{\mathbb{R}}$$

乘积：$\log_{\mathbf{x}}(\mathbf{y}) = (\log_{\mathbf{x}^{\mathbb{H}}}(\mathbf{y}^{\mathbb{H}}), \log_{\mathbf{x}^{\mathbb{S}}}(\mathbf{y}^{\mathbb{S}}), \log_{\mathbf{x}^{\mathbb{R}}}(\mathbf{y}^{\mathbb{R}}))$。

约定：$\mathbf{y} = \mathbf{x}$ 时，$\log_{\mathbf{x}}(\mathbf{x}) = \mathbf{0} \in T_{\mathbf{x}}\mathcal{M}$。

4.4 指数映射

指数映射 $\exp_{\mathbf{x}}(\mathbf{v})$ 将切空间中的向量 $\mathbf{v}$ 推回到流形上。它回答的问题是："从 $\mathbf{x}$ 出发，沿切向量 $\mathbf{v}$ 的方向走 $\|\mathbf{v}\|$ 的测地距离，到达流形上的哪个点？"

定义 4.5（指数映射）。$\exp_{\mathbf{x}} : T_{\mathbf{x}}\mathcal{M} \to \mathcal{M}$，各分量：

- 双曲分量：

$$\exp_{\mathbf{x}^{\mathbb{H}}}(\mathbf{v}^{\mathbb{H}}) = \cosh(\sqrt{|\kappa_h|}\,\|\mathbf{v}^{\mathbb{H}}\|_{\mathrm{L}})\,\mathbf{x}^{\mathbb{H}} + \frac{\sinh(\sqrt{|\kappa_h|}\,\|\mathbf{v}^{\mathbb{H}}\|_{\mathrm{L}})}{\sqrt{|\kappa_h|}\,\|\mathbf{v}^{\mathbb{H}}\|_{\mathrm{L}}}\,\mathbf{v}^{\mathbb{H}}$$

- 球面分量：

$$\exp_{\mathbf{x}^{\mathbb{S}}}(\mathbf{v}^{\mathbb{S}}) = \cos(\sqrt{\kappa_s}\,\|\mathbf{v}^{\mathbb{S}}\|_2)\,\mathbf{x}^{\mathbb{S}} + \frac{\sin(\sqrt{\kappa_s}\,\|\mathbf{v}^{\mathbb{S}}\|_2)}{\sqrt{\kappa_s}\,\|\mathbf{v}^{\mathbb{S}}\|_2}\,\mathbf{v}^{\mathbb{S}}$$

- 欧氏分量：

$$\exp_{\mathbf{x}^{\mathbb{R}}}(\mathbf{v}^{\mathbb{R}}) = \mathbf{x}^{\mathbb{R}} + \mathbf{v}^{\mathbb{R}}$$

乘积：$\exp_{\mathbf{x}}(\mathbf{v}) = (\exp_{\mathbf{x}^{\mathbb{H}}}(\mathbf{v}^{\mathbb{H}}), \exp_{\mathbf{x}^{\mathbb{S}}}(\mathbf{v}^{\mathbb{S}}), \exp_{\mathbf{x}^{\mathbb{R}}}(\mathbf{v}^{\mathbb{R}}))$。

约定：$\mathbf{v} = \mathbf{0}$ 时，$\exp_{\mathbf{x}}(\mathbf{0}) = \mathbf{x}$（各分量中 $\sinh(0)/0$ 和 $\sin(0)/0$ 均取极限值 1）。

命题 4.1（互逆性）。在 injectivity radius 内（双曲与欧氏：∞；球面：$\pi/\sqrt{\kappa_s}$），$\exp_{\mathbf{x}} \circ \log_{\mathbf{x}} = \mathrm{id}_{\mathcal{M}}$ 且 $\log_{\mathbf{x}} \circ \exp_{\mathbf{x}} = \mathrm{id}_{T_{\mathbf{x}}\mathcal{M}}$。

4.5 切空间黎曼范数

定义 4.6（切空间黎曼范数）。对 $\mathbf{v} = (\mathbf{v}^{\mathbb{H}}, \mathbf{v}^{\mathbb{S}}, \mathbf{v}^{\mathbb{R}}) \in T_{\mathbf{x}}\mathcal{M}$：

$$\|\mathbf{v}\|_{T_{\mathbf{x}}\mathcal{M}} = \sqrt{\|\mathbf{v}^{\mathbb{H}}\|_{\mathrm{L}}^2 + \|\mathbf{v}^{\mathbb{S}}\|_2^2 + \|\mathbf{v}^{\mathbb{R}}\|_2^2}$$

---

5. 模型架构：RieFormer

5.1 总体定义

定义 5.1（RieFormer）。 RieFormer 为参数为 θ 的映射：

$$f_\theta(\mathbf{X}_t, \mathbf{E}_t, t, \mathbf{C}_\mathcal{V}, \mathbf{C}_\mathcal{R}, \mathbf{m}) = (\hat{\mathbf{V}}, \hat{\mathbf{P}})$$

输入：$\mathbf{X}_t \in \mathcal{M}^N$，$\mathbf{E}_t \in \{0,1\}^{N\times N\times K}$，$t \in [0,1]$，$\mathbf{C}_\mathcal{V} \in \mathbb{R}^{N\times d_c}$，$\mathbf{C}_\mathcal{R} \in \mathbb{R}^{K\times d_c}$，$\mathbf{m} \in \{0,1\}^N$。

输出：- $\hat{\mathbf{v}}_i \in T_{\mathbf{x}_{t,i}}\mathcal{M}$，节点 i 的切向量预测，$i \in [N]$；- $\hat{\mathbf{P}} \in [0,1]^{N\times N\times K}$，$\hat{\mathbf{P}}_{ij}^{(k)}$ 为边类型概率预测。

记 $\mathbf{X}_t = (\mathbf{x}_{t,1}, \ldots, \mathbf{x}_{t,N}) \in \mathcal{M}^N$，其中 $\mathbf{x}_{t,i} \in \mathcal{M}$ 为节点 i 在时间 t 的流形坐标，通过测地线插值从噪声 $\mathbf{x}_{0,i}$ 到数据 $\mathbf{x}_{1,i}$ 得到。

θ 包含所有可学习参数，含曲率 κ_h, κ_s。

5.2 输入编码层

记号：$[\mathbf{a}\|\mathbf{b}]$ 表示向量拼接（concatenation）。

定义 5.2（坐标投影）。 $\pi : \mathcal{M} \to \mathbb{R}^D$：

$$\pi(\mathbf{x}) = [\mathbf{x}^\mathbb{H}\|\mathbf{x}^\mathbb{S}\|\mathbf{x}^\mathbb{R}]$$

定义 5.3（节点初始嵌入）。

$$\mathbf{h}_i^{V,(0)} = \mathrm{MLP}_{\mathrm{node}}([\pi(\mathbf{x}_{t,i})\|\mathbf{c}_i\|m_i]) \in \mathbb{R}^{d_v}$$

其中输入维度为 $D + d_c + 1$，d_v 为节点隐藏维度。

定义 5.4（边初始嵌入）。

$$\mathbf{h}_{ij}^{E,(0)} = \mathrm{MLP}_{\mathrm{edge}}([\mathbf{E}_{t,ij}\mathbf{W}_{\mathrm{rel}}\|\mathbf{E}_{t,ij}\mathbf{C}_\mathcal{R}]) \in \mathbb{R}^{d_{e'}}$$

其中 $\mathbf{W}_{\mathrm{rel}} \in \mathbb{R}^{K\times d_r}$ 为可学习关系嵌入矩阵，$\mathbf{E}_{t,ij}\mathbf{W}_{\mathrm{rel}} \in \mathbb{R}^{d_r}$ 为激活关系类型的嵌入之和，$\mathbf{E}_{t,ij}\mathbf{C}_\mathcal{R} \in \mathbb{R}^{d_c}$ 为激活关系类型的文本嵌入之和。输入维度为 $d_r + d_c$。

定义 5.5（时间嵌入）。设 $d_t \in \mathbb{Z}_{>0}$ 为偶数，正弦位置编码：

$$\boldsymbol{\psi}(t) = [\sin(\omega_1 t), \cos(\omega_1 t), \ldots, \sin(\omega_{d_t/2} t), \cos(\omega_{d_t/2} t)] \in \mathbb{R}^{d_t}$$

其中 $\omega_l = 10000^{-2l/d_t}$，$l \in [d_t/2]$。线性投影：

$$\mathbf{t}_{\mathrm{emb}} = \mathbf{W}_t\boldsymbol{\psi}(t) + \mathbf{b}_t \in \mathbb{R}^{d_v}$$

其中 $\mathbf{W}_t \in \mathbb{R}^{d_v\times d_t}$，$\mathbf{b}_t \in \mathbb{R}^{d_v}$。

5.3 RieFormer 块

RieFormer 由 $L \in \mathbb{Z}_{>0}$ 个相同结构的块堆叠而成。第 l 层（$l \in [L]$）接收节点嵌入 $\mathbf{H}^{V,(l-1)} \in \mathbb{R}^{N \times d_v}$ 和边嵌入 $\mathbf{H}^{E,(l-1)} \in \mathbb{R}^{N \times N \times d_{e'}}$，输出 $\mathbf{H}^{V,(l)} \in \mathbb{R}^{N \times d_v}$ 和 $\mathbf{H}^{E,(l)} \in \mathbb{R}^{N \times N \times d_{e'}}$。

每个块按以下顺序执行五个子模块：

- A. 流形感知多头注意力（Manifold RoPE + Geodesic Kernel）→ 更新节点嵌入
- B. ATH-Norm → 归一化节点嵌入
- C. 边流自更新 → 更新边嵌入
- D. 双向交叉交互 → 节点与边嵌入互相注入
- E. 文本条件注入 → 通过交叉注意力注入文本语义

5.3.1 子模块 A：流形感知多头注意力

5.3.1 子模块 A：流形感知多头注意力 设 $n_h \in \mathbb{Z}_{>0}$ 为注意力头数，$d_{\text{head}} = d_v / n_h$（要求 $n_h \mid d_v$ 且 $2 \mid d_{\text{head}}$）。

定义 5.6（Manifold RoPE）。对第 s 个注意力头（$s \in [n_h]$），频率 $\omega_l^{(s)} = 10000^{-2l/d_{\text{head}}}$，$l \in [d_{\text{head}}/2]$。对节点对 (i, j)，定义角度：

$$\theta_{ij,l}^{(s)} = \omega_l^{(s)} \cdot d_{\mathcal{M}}(\mathbf{x}_{t,i}, \mathbf{x}_{t,j})$$

旋转矩阵 $\mathbf{R}(\boldsymbol{\theta}_{ij}^{(s)}) \in \mathbb{R}^{d_{\text{head}} \times d_{\text{head}}}$ 为块对角矩阵，由 $d_{\text{head}}/2$ 个 2×2 旋转块组成：

$$\mathbf{R}(\boldsymbol{\theta}_{ij}^{(s)}) = \operatorname{diag}\left(\begin{pmatrix} \cos\theta_{ij,1}^{(s)} & -\sin\theta_{ij,1}^{(s)} \\ \sin\theta_{ij,1}^{(s)} & \cos\theta_{ij,1}^{(s)} \end{pmatrix}, \ldots, \begin{pmatrix} \cos\theta_{ij,d_{\text{head}}/2}^{(s)} & -\sin\theta_{ij,d_{\text{head}}/2}^{(s)} \\ \sin\theta_{ij,d_{\text{head}}/2}^{(s)} & \cos\theta_{ij,d_{\text{head}}/2}^{(s)} \end{pmatrix} \right)$$

定义 5.7（Geodesic Kernel）。对第 s 个注意力头：

$$\kappa^{(s)}(\mathbf{x}_{t,i}, \mathbf{x}_{t,j}) = w_{\mathbb{H}}^{(s)} \kappa_{\mathbb{H}}(\mathbf{x}_{t,i}^{\mathbb{H}}, \mathbf{x}_{t,j}^{\mathbb{H}}) + w_{\mathbb{S}}^{(s)} \kappa_{\mathbb{S}}(\mathbf{x}_{t,i}^{\mathbb{S}}, \mathbf{x}_{t,j}^{\mathbb{S}}) + w_{\mathbb{R}}^{(s)} \kappa_{\mathbb{R}}(\mathbf{x}_{t,i}^{\mathbb{R}}, \mathbf{x}_{t,j}^{\mathbb{R}})$$

其中：- $\kappa_{\mathbb{H}}(\mathbf{a}, \mathbf{b}) = -d_{\mathbb{H}}(\mathbf{a}, \mathbf{b})$ - $\kappa_{\mathbb{S}}(\mathbf{a}, \mathbf{b}) = \kappa_s \cdot \mathbf{a}^\top \mathbf{b}$ - $\kappa_{\mathbb{R}}(\mathbf{a}, \mathbf{b}) = -\|\mathbf{a} - \mathbf{b}\|_2^2$

$w_{\mathbb{H}}^{(s)}, w_{\mathbb{S}}^{(s)}, w_{\mathbb{R}}^{(s)} \in \mathbb{R}$ 为每头独立的可学习权重。

定义 5.8（流形感知注意力）。查询/键/值投影（$s \in [n_h]$）：

$$\mathbf{q}_i^{(s)} = \mathbf{W}_Q^{(s)} \mathbf{h}_i^{V,(l-1)}, \quad \mathbf{k}_j^{(s)} = \mathbf{W}_K^{(s)} \mathbf{h}_j^{V,(l-1)}, \quad \mathbf{v}_j^{(s)} = \mathbf{W}_V^{(s)} \mathbf{h}_j^{V,(l-1)} \in \mathbb{R}^{d_{\text{head}}}$$

其中 $\mathbf{W}_Q^{(s)}, \mathbf{W}_K^{(s)}, \mathbf{W}_V^{(s)} \in \mathbb{R}^{d_{\text{head}} \times d_v}$。

注意力分数：

$$a_{ij}^{(s)} = \frac{(\mathbf{R}(\boldsymbol{\theta}_{ij}^{(s)}) \mathbf{q}_i^{(s)})^\top \mathbf{k}_j^{(s)}}{\sqrt{d_{\text{head}}}} + \beta^{(s)} \kappa^{(s)}(\mathbf{x}_{t,i}, \mathbf{x}_{t,j}) + \mathbf{w}_b^{(s)\top} \mathbf{h}_{ij}^{E,(l-1)}$$

其中 $\beta^{(s)} \in \mathbb{R}$ 为可学习缩放系数，$\mathbf{w}_b^{(s)} \in \mathbb{R}^{d_{e'}}$ 为边偏置权重。

注意力权重：$\alpha_{ij}^{(s)} = \mathrm{softmax}_j(a_{ij}^{(s)})$。

欧氏聚合：

$$\mathbf{o}_i^{(s)} = \sum_{j=1}^{N} \alpha_{ij}^{(s)} \cdot \mathbf{v}_j^{(s)} \in \mathbb{R}^{d_{\mathrm{head}}}$$

多头拼接与投影：

$$\mathrm{MHA}_i = \mathbf{W}_O[\mathbf{o}_i^{(1)} \| \cdots \| \mathbf{o}_i^{(n_h)}] \in \mathbb{R}^{d_v}$$

其中 $\mathbf{W}_O \in \mathbb{R}^{d_v \times d_v}$。

残差连接：$\tilde{\mathbf{h}}_i^V = \mathbf{h}_i^{V,(l-1)} + \mathrm{MHA}_i$。

5.3.3 子模块 C：边流自更新 边嵌入通过分解注意力独立更新：对边 (i,j)，分别聚合头节点 i 的其他出边和尾节点 j 的其他入边的信息。

定义 5.11（分解边注意力）。对边 (i,j)：

头侧聚合（i 的其他出边）：

$$\mathbf{g}_{ij}^{\mathrm{head}} = \sum_{p \in [N] \setminus \{j\}} \gamma_{ip \to ij}^{\mathrm{head}} \cdot \mathbf{W}_{\mathrm{Ev}}^{\mathrm{head}} \mathbf{h}_{ip}^{E,(l-1)}$$

尾侧聚合（j 的其他入边）：

$$\mathbf{g}_{ij}^{\mathrm{tail}} = \sum_{p \in [N] \setminus \{i\}} \gamma_{pj \to ij}^{\mathrm{tail}} \cdot \mathbf{W}_{\mathrm{Ev}}^{\mathrm{tail}} \mathbf{h}_{pj}^{E,(l-1)}$$

注意力权重：

$$\gamma_{ip \to ij}^{\mathrm{head}} = \mathrm{softmax}_p \left(\frac{(\mathbf{W}_{\mathrm{Eq}}^{\mathrm{head}} \mathbf{h}_{ij}^{E,(l-1)})^\top (\mathbf{W}_{\mathrm{Ek}}^{\mathrm{head}} \mathbf{h}_{ip}^{E,(l-1)})}{\sqrt{d_{e'}}} \right)$$

尾侧 $\gamma_{pj \to ij}^{\mathrm{tail}}$ 类似，使用独立的权重矩阵 $\mathbf{W}_{\mathrm{Eq}}^{\mathrm{tail}}, \mathbf{W}_{\mathrm{Ek}}^{\mathrm{tail}}$。

所有权重矩阵 $\mathbf{W}_{\mathrm{Eq}}^{\mathrm{head}}, \mathbf{W}_{\mathrm{Ek}}^{\mathrm{head}}, \mathbf{W}_{\mathrm{Ev}}^{\mathrm{head}}, \mathbf{W}_{\mathrm{Eq}}^{\mathrm{tail}}, \mathbf{W}_{\mathrm{Ek}}^{\mathrm{tail}}, \mathbf{W}_{\mathrm{Ev}}^{\mathrm{tail}} \in \mathbb{R}^{d_{e'} \times d_{e'}}$。

残差更新：

$$\tilde{\mathbf{h}}_{ij}^E = \mathbf{h}_{ij}^{E,(l-1)} + \mathrm{MLP}_{\text{E-up}} \left([\mathbf{h}_{ij}^{E,(l-1)} \| \mathbf{g}_{ij}^{\mathrm{head}} \| \mathbf{g}_{ij}^{\mathrm{tail}}] \right)$$

其中 $\mathrm{MLP}_{\text{E-up}} : \mathbb{R}^{3d_{e'}} \to \mathbb{R}^{d_{e'}}$。

经 LayerNorm：$\bar{\mathbf{h}}_{ij}^E = \mathrm{LN}(\tilde{\mathbf{h}}_{ij}^E)$。

5.3.4 子模块 D：双向交叉交互　**定义 5.12（边 → 节点聚合）**。对节点 i，聚合其相关边嵌入：

$$\hat{\mathbf{h}}_i^V = \bar{\mathbf{h}}_i^V + \mathrm{MLP}_{E\to V}\left(\sum_{j=1}^{N} \alpha_{ij}^{E\to V} \cdot \mathbf{W}_{\mathrm{Ev2n}} \bar{\mathbf{h}}_{ij}^E\right)$$

其中 $\mathbf{W}_{\mathrm{Ev2n}} \in \mathbb{R}^{d_v \times d_{e'}}$，$\mathrm{MLP}_{E\to V} : \mathbb{R}^{d_v} \to \mathbb{R}^{d_v}$。注意力权重：

$$\alpha_{ij}^{E\to V} = \mathrm{softmax}_j\left(\frac{(\mathbf{W}_Q^{E\to V}\bar{\mathbf{h}}_i^V)^\top (\mathbf{W}_K^{E\to V}\bar{\mathbf{h}}_{ij}^E)}{\sqrt{d_v}}\right)$$

其中 $\mathbf{W}_Q^{E\to V} \in \mathbb{R}^{d_v \times d_v}$，$\mathbf{W}_K^{E\to V} \in \mathbb{R}^{d_v \times d_{e'}}$。

定义 5.13（节点 → 边注入）。对边 (i, j)：

$$\hat{\mathbf{h}}_{ij}^E = \bar{\mathbf{h}}_{ij}^E + \mathrm{MLP}_{V\to E}\Big([\hat{\mathbf{h}}_i^V \| \hat{\mathbf{h}}_j^V \| \hat{\mathbf{h}}_i^V \odot \hat{\mathbf{h}}_j^V]\Big)$$

其中 $\mathrm{MLP}_{V\to E} : \mathbb{R}^{3d_v} \to \mathbb{R}^{d_{e'}}$。

5.3.5 子模块 E：文本条件注入　**定义 5.14（文本交叉注意力）**。对节点 i，以节点嵌入为 query、文本条件为 key/value：

$$\mathbf{q}_i^{\mathrm{text}} = \mathbf{W}_Q^{\mathrm{text}} \hat{\mathbf{h}}_i^V, \quad \mathbf{k}_j^{\mathrm{text}} = \mathbf{W}_K^{\mathrm{text}} \mathbf{c}_j, \quad \mathbf{v}_j^{\mathrm{text}} = \mathbf{W}_V^{\mathrm{text}} \mathbf{c}_j$$

其中 $\mathbf{W}_Q^{\mathrm{text}} \in \mathbb{R}^{d_v \times d_v}$，$\mathbf{W}_K^{\mathrm{text}}, \mathbf{W}_V^{\mathrm{text}} \in \mathbb{R}^{d_v \times d_c}$。

交叉注意力：

$$\mathrm{CrossAttn}_i = \sum_{j=1}^{N} \mathrm{softmax}_j\left(\frac{\mathbf{q}_i^{\mathrm{text}\top} \mathbf{k}_j^{\mathrm{text}}}{\sqrt{d_v}}\right) \cdot \mathbf{v}_j^{\mathrm{text}}$$

定义 5.15（第 l 层输出）。- 节点：$\mathbf{h}_i^{V,(l)} = \mathrm{LN}(\hat{\mathbf{h}}_i^V + \mathrm{CrossAttn}_i)$ - 边：$\mathbf{h}_{ij}^{E,(l)} = \hat{\mathbf{h}}_{ij}^E$

5.4 输出投影层

5.4.1 向量场输出头　**定义 5.16（切空间投影）**。对任意 $\hat{\mathbf{u}} \in \mathbb{R}^D$，按坐标投影 π 的逆序拆分为 $\hat{\mathbf{u}}^{\mathbb{H}} \in \mathbb{R}^{d_h+1}$，$\hat{\mathbf{u}}^{\mathbb{S}} \in \mathbb{R}^{d_s+1}$，$\hat{\mathbf{u}}^{\mathbb{R}} \in \mathbb{R}^{d_e}$。投影到 $T_{\mathbf{x}_t}\mathcal{M}$：

$$\hat{\mathbf{v}}^{\mathbb{H}} = \hat{\mathbf{u}}^{\mathbb{H}} - \kappa_h \langle \hat{\mathbf{u}}^{\mathbb{H}}, \mathbf{x}_t^{\mathbb{H}} \rangle_{\mathrm{L}} \cdot \mathbf{x}_t^{\mathbb{H}} \in T_{\mathbf{x}_t^{\mathbb{H}}}\mathbb{H}$$

$$\hat{\mathbf{v}}^{\mathbb{S}} = \hat{\mathbf{u}}^{\mathbb{S}} - \kappa_s (\mathbf{x}_t^{\mathbb{S}\top} \hat{\mathbf{u}}^{\mathbb{S}}) \cdot \mathbf{x}_t^{\mathbb{S}} \in T_{\mathbf{x}_t^{\mathbb{S}}}\mathbb{S}$$

$$\hat{\mathbf{v}}^{\mathbb{R}} = \hat{\mathbf{u}}^{\mathbb{R}} \in \mathbb{R}^{d_e}$$

定义 5.17（向量场预测）。对节点 i：

$$\hat{\mathbf{u}}_i = \mathrm{MLP}_{\mathrm{vec}}(\mathbf{h}_i^{V,(L)}) \in \mathbb{R}^D$$

其中 $\mathrm{MLP}_{\mathrm{vec}} : \mathbb{R}^{d_v} \to \mathbb{R}^D$。经定义 5.16 投影后得 $\hat{\mathbf{v}}_i = (\hat{\mathbf{v}}_i^{\mathbb{H}}, \hat{\mathbf{v}}_i^{\mathbb{S}}, \hat{\mathbf{v}}_i^{\mathbb{R}}) \in T_{\mathbf{x}_{t,i}}\mathcal{M}$。

5.4.2 边类型输出头 **定义 5.18（关系交互层）**。对边 (i,j) 和每个关系类型 $k \in [K]$，构造候选关系特征：

$$\mathbf{r}_{ij}^{(k)} = \mathrm{MLP}_{\text{rel-proj}}\Big([\mathbf{h}_{ij}^{E,(L)} \| \mathbf{c}_{r_k}]\Big) \in \mathbb{R}^{d_{e'}}$$

其中 $\mathrm{MLP}_{\text{rel-proj}} : \mathbb{R}^{d_{e'}+d_c} \to \mathbb{R}^{d_{e'}}$。

K 个候选特征 $\{\mathbf{r}_{ij}^{(1)}, \ldots, \mathbf{r}_{ij}^{(K)}\}$ 经关系 Transformer（在关系维度上的自注意力）交互后得 $\tilde{\mathbf{r}}_{ij}^{(k)} \in \mathbb{R}^{d_{e'}}$，$k \in [K]$。

定义 5.19（边类型概率）。

$$\hat{\mathbf{P}}_{ij}^{(k)} = \sigma(\mathbf{w}_{\text{cls}}^{\top} \tilde{\mathbf{r}}_{ij}^{(k)} + b_{\text{cls}}) \in [0,1]$$

其中 $\sigma(\cdot)$ 为 sigmoid 函数，$\mathbf{w}_{\text{cls}} \in \mathbb{R}^{d_{e'}}$，$b_{\text{cls}} \in \mathbb{R}$。各关系类型独立预测（对应多热标签）。

5.5 排列等变性

命题 5.1（排列等变性）。对任意排列矩阵 $\mathbf{\Pi} \in \{0,1\}^{N \times N}$：

$$f_\theta(\mathbf{\Pi}\mathbf{X}_t, \mathbf{\Pi}\mathbf{E}_t\mathbf{\Pi}^{\top}, t, \mathbf{\Pi}\mathbf{C}_{\mathcal{V}}, \mathbf{C}_{\mathcal{R}}, \mathbf{\Pi}\mathbf{m}) = (\mathbf{\Pi}\hat{\mathbf{V}}, \mathbf{\Pi}\hat{\mathbf{P}}\mathbf{\Pi}^{\top})$$

其中 $\mathbf{C}_{\mathcal{R}}$ 和 t 不受排列影响。

---

6. 离散-连续联合流匹配

约定：$t = 0$ 对应噪声端，$t = 1$ 对应数据端。$\mathbf{X}_1, \mathbf{E}_1$ 为训练数据（来自子图），$\mathbf{X}_0, \mathbf{E}_0$ 为噪声采样。

6.1 噪声先验分布

定义 6.1（连续噪声先验）。对每个节点 $i \in [N]$，各分量独立采样：- 双曲分量：$\mathbf{x}_{0,i}^{\mathbb{H}} \sim \mathrm{Uniform}(B_{\mathbb{H}}(\mathbf{x}_{\varnothing}^{\mathbb{H}}, R_{\mathbb{H}}))$，即在以锚点 $\mathbf{x}_{\varnothing}^{\mathbb{H}}$ 为中心、测地半径 $R_{\mathbb{H}} > 0$ 的测地球内关于黎曼体积测度均匀采样；- 球面分量：$\mathbf{x}_{0,i}^{\mathbb{S}} \sim \mathrm{Uniform}(\mathbb{S}_{\kappa_s}^{d_s})$，即关于球面体积测度的均匀分布；- 欧氏分量：$\mathbf{x}_{0,i}^{\mathbb{R}} \sim \mathcal{N}(\mathbf{0}, \sigma_0^2 \mathbf{I}_{d_e})$。

其中 $R_{\mathbb{H}} > 0$ 和 $\sigma_0 > 0$ 为超参数。记连续噪声先验为 $p_0^{\mathcal{M}}$。

定义 6.2（离散噪声先验）。对每对 $(i,j) \in [N]^2$ 和每个关系类型 $k \in [K]$，独立采样：

$$\mathbf{E}_{0,ij}^{(k)} \sim \mathrm{Bernoulli}(\rho_k)$$

其中边际频率：

$$\rho_k = \frac{\sum_{\mathcal{G} \in \mathcal{D}} \sum_{i=1}^{N} \sum_{j=1}^{N} \mathbf{E}_{1,ij}^{(k)}}{|\mathcal{D}| \cdot N^2}$$

即关系类型 r_k 在训练集中的平均出现频率（虚节点边为零，不影响分子）。

6.2 前向插值过程

定义 6.3（连续插值）。对每个节点 $i \in [N]$，在 $\mathbf{x}_{0,i}$（噪声）与 $\mathbf{x}_{1,i}$（数据）之间沿测地线插值：

$$\mathbf{x}_{t,i} = \exp_{\mathbf{x}_{0,i}}\Big(t \cdot \log_{\mathbf{x}_{0,i}}(\mathbf{x}_{1,i})\Big) \in \mathcal{M}, \quad t \in [0,1]$$

边界条件：$\mathbf{x}_{0,i} = \mathbf{x}_{0,i}$（噪声），$\mathbf{x}_{1,i} = \mathbf{x}_{1,i}$（数据）。

定义 6.4（离散插值）。对每对 $(i,j) \in [N]^2$，独立采样掩码：

$$z_{ij} \sim \mathrm{Bernoulli}(t)$$

$$\mathbf{E}_{t,ij} = z_{ij} \cdot \mathbf{E}_{1,ij} + (1 - z_{ij}) \cdot \mathbf{E}_{0,ij}$$

同一对 (i,j) 的所有 K 个关系类型共享同一个 z_{ij}，即整体取数据端或噪声端。不同方向 z_{ij} 与 z_{ji} 独立采样。

6.3 条件目标

定义 6.5（条件向量场目标）。对每个节点 $i \in [N]$：

$$\mathbf{u}_{t,i} = \frac{1}{1-t} \log_{\mathbf{x}_{t,i}}(\mathbf{x}_{1,i}) \in T_{\mathbf{x}_{t,i}}\mathcal{M}$$

即从当前位置 $\mathbf{x}_{t,i}$ 指向数据点 $\mathbf{x}_{1,i}$ 的切向量，按剩余时间 $1-t$ 缩放为速度：沿此速度走 $1-t$ 时间恰好到达 $\mathbf{x}_{1,i}$。训练时 $t \sim \mathrm{Uniform}(0, 1-\epsilon_t)$，$\epsilon_t > 0$ 为小常数，避免 $t \to 1$ 时的奇异性。

定义 6.6（边类型目标）。对每对 $(i,j) \in [N]^2$ 和每个关系类型 $k \in [K]$：

$$\mathbf{E}_{1,ij}^{(k)} \in \{0,1\}$$

即数据端的真实边类型标签。

6.4 训练损失函数

定义 6.7（流形向量场损失）。

$$\mathcal{L}_{\mathrm{cont}} = \frac{1}{N} \sum_{i=1}^{N} m_i \cdot \|\hat{\mathbf{v}}_i - \mathbf{u}_{t,i}\|^2_{T_{\mathbf{x}_{t,i}}\mathcal{M}}$$

其中 $\|\cdot\|_{T_{\mathbf{x}_{t,i}}\mathcal{M}}$ 为定义 4.6 的切空间黎曼范数。虚节点（$m_i = 0$）不贡献损失。

定义 6.8（边类型损失）。设 $\mathcal{S} \subseteq [N]^2$ 为采样的边对集合。

$$\mathcal{L}_{\mathrm{disc}} = \frac{1}{|\mathcal{S}|} \sum_{(i,j)\in\mathcal{S}} \sum_{k=1}^{K} \mathrm{BCE}_{\mathrm{w}}(\hat{\mathbf{P}}_{ij}^{(k)}, \mathbf{E}_{1,ij}^{(k)})$$

其中加权二元交叉熵：

$$\mathrm{BCE_w}(\hat{p}, y) = -\left[w_k^+ \cdot y \cdot \log(\hat{p} + \epsilon_p) + (1 - y) \cdot \log(1 - \hat{p} + \epsilon_p)\right]$$

正样本权重 $w_k^+ = \min\left(\frac{1-\rho_k}{\rho_k}, w_{\max}\right)$ 校正类别不平衡，$w_{\max} > 0$ 为截断上限，$\epsilon_p > 0$ 为数值稳定常数。

定义 6.9（图-文对比损失）。将数据端坐标投影到对齐空间：

$$\mathbf{g}_i = \mathrm{MLP}_{\mathrm{proj}}(\pi(\mathbf{x}_{1,i})) \in \mathbb{R}^{d_{\mathrm{a}}}$$

其中 $\mathrm{MLP}_{\mathrm{proj}} : \mathbb{R}^D \to \mathbb{R}^{d_{\mathrm{a}}}$，$d_{\mathrm{a}}$ 为对齐空间维度。

余弦相似度：$\mathrm{sim}(\mathbf{g}_i, \mathbf{c}_j) = \frac{\mathbf{g}_i^\top \mathbf{c}_j}{\|\mathbf{g}_i\|_2 \|\mathbf{c}_j\|_2}$

设 $\mathcal{B} \subseteq [N]$ 为 mini-batch 中的节点索引集，对称对比损失：

$$\mathcal{L}_{\mathrm{align}} = \frac{1}{2}\left(\mathcal{L}_{\mathrm{align}}^{g\to c} + \mathcal{L}_{\mathrm{align}}^{c\to g}\right)$$

其中：

$$\mathcal{L}_{\mathrm{align}}^{g\to c} = -\frac{1}{|\mathcal{B}|}\sum_{i\in\mathcal{B}} \log \frac{\exp(\mathrm{sim}(\mathbf{g}_i, \mathbf{c}_i)/\tau)}{\sum_{j\in\mathcal{B}} \exp(\mathrm{sim}(\mathbf{g}_i, \mathbf{c}_j)/\tau)}$$

$\mathcal{L}_{\mathrm{align}}^{c\to g}$ 对称定义。$\tau > 0$ 为温度超参数。

定义 6.10（总训练损失）。

$$\mathcal{L} = \mathcal{L}_{\mathrm{cont}} + \lambda\, \mathcal{L}_{\mathrm{disc}} + \mu\, \mathcal{L}_{\mathrm{align}}$$

其中 $\lambda, \mu > 0$ 为损失权重超参数。

6.5 训练与推理算法

算法 1：RiemannFM 单步训练

输入：训练子图 $(\mathbf{X}_1, \mathbf{E}_1, \mathbf{C}_{\mathcal{V}}, \mathbf{C}_{\mathcal{R}}, \mathbf{m})$，参数 θ **输出**：损失 $\mathcal{L}$

1. 采样 $t \sim \mathrm{Uniform}(0, 1 - \epsilon_t)$
2. 对 $i \in [N]$：采样 $\mathbf{x}_{0,i} \sim p_0^{\mathcal{M}}$（定义 6.1）
3. 对 $(i, j) \in [N]^2$，$k \in [K]$：采样 $\mathbf{E}_{0,ij}^{(k)} \sim \mathrm{Bernoulli}(\rho_k)$（定义 6.2）
4. 对 $i \in [N]$：$\mathbf{x}_{t,i} = \exp_{\mathbf{x}_{0,i}}(t \cdot \log_{\mathbf{x}_{0,i}}(\mathbf{x}_{1,i}))$（定义 6.3）
5. 对 $(i, j) \in [N]^2$：采样 $z_{ij} \sim \mathrm{Bernoulli}(t)$，$\mathbf{E}_{t,ij} = z_{ij}\mathbf{E}_{1,ij} + (1 - z_{ij})\mathbf{E}_{0,ij}$（定义 6.4）
6. $(\hat{\mathbf{V}}, \hat{\mathbf{P}}) = f_\theta(\mathbf{X}_t, \mathbf{E}_t, t, \mathbf{C}_{\mathcal{V}}, \mathbf{C}_{\mathcal{R}}, \mathbf{m})$（定义 5.1）
7. 对 $i \in [N]$：$\mathbf{u}_{t,i} = \frac{1}{1-t}\log_{\mathbf{x}_{t,i}}(\mathbf{x}_{1,i})$（定义 6.5）
8. 计算 $\mathcal{L} = \mathcal{L}_{\mathrm{cont}} + \lambda\, \mathcal{L}_{\mathrm{disc}} + \mu\, \mathcal{L}_{\mathrm{align}}$（定义 6.10）
9. Riemannian Adam 更新 θ：对欧氏参数用标准 Adam，对曲率参数用黎曼梯度

10. 曲率投影：$\kappa_h \leftarrow \min(\kappa_h, -\epsilon_\kappa)$，$\kappa_s \leftarrow \max(\kappa_s, \epsilon_\kappa)$

其中 $\epsilon_t > 0$，$\epsilon_\kappa > 0$ 为小常数。

算法 2：RiemannFM 推理

输入：文本条件 $\mathbf{C}_\mathcal{V}, \mathbf{C}_\mathcal{R}$，步数 $T \in \mathbb{Z}_{>0}$，步长 $\Delta t = 1/T$ **输出**：$(\mathbf{X}_1, \mathbf{E}_1, \mathbf{m}_{\text{pred}})$

1. 采样 $\mathbf{X}_0, \mathbf{E}_0$（定义 6.1, 6.2）
2. **for** $s = 0, 1, \ldots, T-1$ **do**：
   - $t = s \cdot \Delta t$
   - $(\hat{\mathbf{V}}, \hat{\mathbf{P}}) = f_\theta(\mathbf{X}_t, \mathbf{E}_t, t, \mathbf{C}_\mathcal{V}, \mathbf{C}_\mathcal{R}, \mathbf{m})$
   - 对 $i \in [N]$：$\mathbf{x}_{t+\Delta t,i} = \exp_{\mathbf{x}_{t,i}}(\Delta t \cdot \hat{\mathbf{v}}_i)$
   - 对 $(i,j) \in [N]^2$，$k \in [K]$：以概率 $p_{\text{flip}}(t, \Delta t) = \min\left(\frac{\Delta t}{1-t}, 1\right)$ 更新 $\mathbf{E}^{(k)}_{t+\Delta t,ij} = \mathbb{1}[\hat{\mathbf{P}}^{(k)}_{ij} > 0.5]$，否则保持 $\mathbf{E}^{(k)}_{t,ij}$ 不变
3. 虚节点移除：$m_{\text{pred},i} = \mathbb{1}[d_\mathcal{M}(\mathbf{x}_{1,i}, \mathbf{x}_\varnothing) \geq \epsilon_{\text{null}}]$
4. 边二值化：$\mathbf{E}^{(k)}_{1,ij} \leftarrow \mathbb{1}[\hat{\mathbf{P}}^{(k)}_{ij} > p_{\text{thresh}}]$

其中 $\epsilon_{\text{null}} > 0$ 为虚节点检测阈值，$p_{\text{thresh}} \in (0,1)$ 为边二值化阈值。

---

7. 下游任务微调

7.1 统一掩码框架

定义 7.1（任务掩码）。- 节点任务掩码 $\mathbf{m}^{\text{task}} \in \{0,1\}^N$：$m_i^{\text{task}} = 1$ 表示待预测，$m_i^{\text{task}} = 0$ 表示已知条件。- 边任务掩码 $\mathbf{M}^{\text{task}} \in \{0,1\}^{N \times N}$：$M_{ij}^{\text{task}} = 1$ 表示待预测，$M_{ij}^{\text{task}} = 0$ 表示已知条件。

定义 7.2（条件化含噪输入）。待预测部分按第 6 节正常插值，已知部分保持数据端真实值：

$$\mathbf{x}^{\text{cond}}_{t,i} = \begin{cases} \exp_{\mathbf{x}_{0,i}}(t \cdot \log_{\mathbf{x}_{0,i}}(\mathbf{x}_{1,i})) & m_i^{\text{task}} = 1 \\ \mathbf{x}_{1,i} & m_i^{\text{task}} = 0 \end{cases}$$

$$\mathbf{E}^{\text{cond}}_{t,ij} = \begin{cases} z_{ij} \cdot \mathbf{E}_{1,ij} + (1 - z_{ij}) \cdot \mathbf{E}_{0,ij} & M_{ij}^{\text{task}} = 1 \\ \mathbf{E}_{1,ij} & M_{ij}^{\text{task}} = 0 \end{cases}$$

定义 7.3（条件化微调损失）。损失仅在待预测部分上计算：

$$\mathcal{L}^{\text{task}}_{\text{cont}} = \frac{1}{\sum_i m_i^{\text{task}} \cdot m_i} \sum_{i=1}^{N} m_i^{\text{task}} \cdot m_i \cdot \|\hat{\mathbf{v}}_i - \mathbf{u}_{t,i}\|^2_{T_{\mathbf{x}_{t,i}}\mathcal{M}}$$

$$\mathcal{L}^{\text{task}}_{\text{disc}} = \frac{1}{\sum_{i,j} M_{ij}^{\text{task}}} \sum_{(i,j)} M_{ij}^{\text{task}} \sum_{k=1}^{K} \text{BCE}_{\text{w}}(\hat{\mathbf{P}}^{(k)}_{ij}, \mathbf{E}^{(k)}_{1,ij})$$

注意 $\mathcal{L}^{\text{task}}_{\text{cont}}$ 中同时要求 $m_i^{\text{task}} = 1$（待预测）和 $m_i = 1$（真实节点，非虚节点）。

7.2 任务一：知识图谱补全

掩码策略。给定训练子图，按以下规则构造任务掩码：

- 边掩码：对每条存在的边 (i,j)（即 $\mathbf{E}_{1,ij} \neq \mathbf{0}_K$），独立以概率 p^E_{mask} 设置 $M^{\text{task}}_{ij} = 1$；
- 节点掩码：对每个真实节点 i（$m_i = 1$），独立以概率 p^V_{mask} 设置 $m^{\text{task}}_i = 1$，同时掩码其所有关联边：$\forall j \in [N]$，$M^{\text{task}}_{ij} = M^{\text{task}}_{ji} = 1$；
- 其余位置 $m^{\text{task}}_i = 0$，$M^{\text{task}}_{ij} = 0$。

其中 $p^E_{\text{mask}}, p^V_{\text{mask}} \in (0,1)$ 为超参数。

微调损失。

$$\mathcal{L}_{\text{KGC}} = \mathcal{L}^{\text{task}}_{\text{cont}} + \lambda_{\text{KGC}}\, \mathcal{L}^{\text{task}}_{\text{disc}}$$

其中 $\lambda_{\text{KGC}} > 0$ 为权重超参数。

评估。对待预测事实 $(v_i, r_k, ?)$，以模型输出 $\hat{\mathbf{P}}^{(k)}_{ij}$ 对所有候选实体 v_j 排序。指标：- $\text{MRR} = \frac{1}{|\mathcal{Q}|}\sum_{q\in\mathcal{Q}} \frac{1}{\text{rank}_q}$，其中 $\mathcal{Q}$ 为测试查询集；- $\text{Hits@}n = \frac{1}{|\mathcal{Q}|}\sum_{q\in\mathcal{Q}} \mathbb{1}[\text{rank}_q \leq n]$，$n \in \{1,3,10\}$。

7.3 任务二：文本条件子图生成

问题设定。给定文本查询 $q \in \Sigma^*$，生成一个与查询语义匹配的子图 $\mathcal{G}$。

掩码策略。全部掩码：

$$m^{\text{task}}_i = 1 \quad \forall i \in [N], \qquad M^{\text{task}}_{ij} = 1 \quad \forall (i,j) \in [N]^2$$

文本条件替换。将所有节点的文本条件替换为查询嵌入：

$$\mathbf{c}_q = \phi_{\text{text}}(q) \in \mathbb{R}^{d_c}, \qquad \mathbf{C}_{\mathcal{V}} = \mathbf{1}_N \mathbf{c}_q^\top \in \mathbb{R}^{N\times d_c}$$

其中 $\mathbf{1}_N \in \mathbb{R}^N$ 为全 1 向量。$\mathbf{C}_{\mathcal{R}}$ 保持不变。

微调损失。由于全部掩码，条件化损失退化为预训练损失形式：

$$\mathcal{L}_{\text{T2G}} = \mathcal{L}_{\text{cont}} + \lambda_{\text{T2G}}\, \mathcal{L}_{\text{disc}} + \mu_{\text{T2G}}\, \mathcal{L}_{\text{align}}$$

其中 $\lambda_{\text{T2G}}, \mu_{\text{T2G}} > 0$ 为权重超参数。对比损失 $\mathcal{L}_{\text{align}}$ 鼓励生成的节点坐标与查询文本 $\mathbf{c}_q$ 在对齐空间中接近。

评估。将生成子图与真实子图通过最大匹配对齐后计算：- **节点 F1**：基于匹配节点的文本相似度，以 BERTScore 阈值判定匹配成功；- **关系 F1**：在匹配的节点对上，比较预测的边类型集合与真实边类型集合的 F1；- **BERTScore**：生成子图中节点文本描述与真实子图的平均 BERTScore。

7.4 任务三：图异常检测

问题设定。给定一个子图 $\mathcal{G}$，检测其中的异常边和异常节点。本任务直接使用预训练模型，无需微调。

异常分数构造。对待检测子图，以 $\mathbf{X}_1 = \mathbf{X}$，$\mathbf{E}_1 = \mathbf{E}$ 为数据端，按定义 6.1–6.2 采样噪声 $\mathbf{X}_0, \mathbf{E}_0$，按定义 6.3–6.4 构造含噪输入 $\mathbf{X}_t, \mathbf{E}_t$。

定义 7.4（边异常分数）。设 $\mathcal{T} = \{t_1, \ldots, t_{|\mathcal{T}|}\} \subset (0,1)$ 为预选时间步集合（如均匀网格）。对每条存在的边 (i,j,k)（$\mathbf{E}_{1,ij}^{(k)} = 1$）：

$$S_{ij}^{(k)} = 1 - \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} \hat{\mathbf{P}}_{ij}^{(k)}(f_\theta(\mathbf{X}_t, \mathbf{E}_t, t, \mathbf{C}_\mathcal{V}, \mathbf{C}_\mathcal{R}, \mathbf{m}))$$

直觉：预训练模型对正常事实给出高概率 $\hat{\mathbf{P}}_{ij}^{(k)} \approx 1$，异常分数 $S_{ij}^{(k)} \approx 0$；对异常事实给出低概率，异常分数接近 1。多时间步取平均提高鲁棒性。

定义 7.5（节点异常分数）。设 $\mathcal{N}_i = \{j \in [N] : \mathbf{E}_{1,ij} \neq \mathbf{0}_K\}$ 为节点 i 的出边邻居集。

$$S_i = \frac{1}{|\mathcal{N}_i|} \sum_{j \in \mathcal{N}_i} \max_{k:\, \mathbf{E}_{1,ij}^{(k)} = 1} S_{ij}^{(k)}$$

即节点的异常程度为其所有出边中最可疑关系的平均异常分数。

评估。 AUROC，AP（Average Precision）。

符号速查表

基础集合与索引

符号	类型	值域	含义
$\mathcal{V}$	集合	—	实体集
$\mathcal{R}$	集合	—	关系类型集
K	标量	$\mathbb{Z}_{>0}$	关系类型总数，$K \triangleq \lvert\mathcal{R}\rvert$
$\mathcal{K}$	图	—	知识图谱 $(\mathcal{V}, \mathcal{E})$
$\mathcal{E}$	集合	$\subseteq \mathcal{V} \times \mathcal{R} \times \mathcal{V}$	事实集
$\mathcal{G}$	图	—	子图 $(\mathcal{V}_\mathcal{G}, \mathcal{E}_\mathcal{G})$
N	标量	$\mathbb{Z}_{>0}$	子图节点数（填充后 $N = N_{\max}$）
$N_{\max}$	标量	$\mathbb{Z}_{>0}$	子图节点数上界
$[n]$	集合	—	$\{1, 2, \ldots, n\}$
$\mathcal{D}$	集合	—	训练数据集（子图集合）

流形与几何

符号	类型	值域	含义
$\mathcal{M}$	流形	—	乘积流形 $\mathbb{H}_{\kappa_h}^{d_h} \times \mathbb{S}_{\kappa_s}^{d_s} \times \mathbb{R}^{d_e}$
d_h, d_s, d_e	标量	$\mathbb{Z}_{>0}$	双曲、球面、欧氏子空间内在维度
D	标量	$\mathbb{Z}_{>0}$	总环境维度，$D = (d_h + 1) + (d_s + 1) + d_e$
κ_h	标量	$\mathbb{R}_{<0}$	双曲空间曲率（可学习）
κ_s	标量	$\mathbb{R}_{>0}$	球面曲率（可学习）
$\langle \cdot, \cdot \rangle_{\mathrm{L}}$	运算	$\mathbb{R}$	Lorentz 内积
$T_{\mathbf{x}}\mathcal{M}$	空间	—	$\mathbf{x}$ 处的切空间
$\exp_{\mathbf{x}}$	映射	$T_{\mathbf{x}}\mathcal{M} \to \mathcal{M}$	指数映射
$\log_{\mathbf{x}}$	映射	$\mathcal{M} \to T_{\mathbf{x}}\mathcal{M}$	对数映射
$d_{\mathcal{M}}$	函数	$\mathcal{M} \times \mathcal{M} \to \mathbb{R}_{\geq 0}$	乘积流形测地距离
$d_{\mathbb{H}}, d_{\mathbb{S}}, d_{\mathbb{R}}$	函数	—	各子空间测地距离
π	映射	$\mathcal{M} \to \mathbb{R}^D$	坐标投影
$\mathbf{x}_{\varnothing}$	向量	$\mathcal{M}$	虚节点锚点

子图表示

符号	类型	值域	含义
$\mathbf{x}_i$	向量	$\mathcal{M}$	节点 i 的流形坐标
$\mathbf{x}_i^{\mathbb{H}}, \mathbf{x}_i^{\mathbb{S}}, \mathbf{x}_i^{\mathbb{R}}$	向量	$\mathbb{R}^{d_h+1}, \mathbb{R}^{d_s+1}, \mathbb{R}^{d_e}$	各子空间分量
$\mathbf{X}$	元组	$\mathcal{M}^N$	节点坐标序列
$\mathbf{E}$	张量	$\{0,1\}^{N \times N \times K}$	边类型张量
$\mathbf{E}_{ij}$	向量	$\{0,1\}^K$	节点 i 到 j 的多热边类型
$\mathbf{C}_{\mathcal{V}}$	矩阵	$\mathbb{R}^{N \times d_c}$	节点文本条件矩阵
$\mathbf{C}_{\mathcal{R}}$	矩阵	$\mathbb{R}^{K \times d_c}$	关系文本条件矩阵
$\mathbf{c}_i$	向量	$\mathbb{R}^{d_c}$	节点 i 的文本条件（$\mathbf{c}_i \triangleq \mathbf{c}_{v_i}$）
$\mathbf{c}_{r_k}$	向量	$\mathbb{R}^{d_c}$	关系 r_k 的文本条件

符号	类型	值域	含义
$\mathbf{m}$	向量	$\{0,1\}^N$	虚节点掩码
ϕ_{text}	映射	$\Sigma^* \to \mathbb{R}^{d_c}$	预训练文本编码器
d_c	标量	$\mathbb{Z}_{>0}$	文本编码器输出维度

模型架构（RieFormer）

符号	类型	值域	含义
f_θ	映射	—	RieFormer 模型
θ	—	—	所有可学习参数（含 κ_h, κ_s）
L	标量	$\mathbb{Z}_{>0}$	RieFormer 层数
d_v	标量	$\mathbb{Z}_{>0}$	节点隐藏维度
$d_{e'}$	标量	$\mathbb{Z}_{>0}$	边隐藏维度
d_r	标量	$\mathbb{Z}_{>0}$	关系嵌入维度
d_t	标量	$\mathbb{Z}_{>0}$（偶数）	时间嵌入维度
d_{head}	标量	$\mathbb{Z}_{>0}$（偶数）	注意力头维度，$d_{\text{head}} = d_v/n_h$
d_{a}	标量	$\mathbb{Z}_{>0}$	对齐空间维度
n_h	标量	$\mathbb{Z}_{>0}$	注意力头数
$\mathbf{h}_i^{V,(l)}$	向量	$\mathbb{R}^{d_v}$	第 l 层节点 i 的嵌入
$\mathbf{h}_{ij}^{E,(l)}$	向量	$\mathbb{R}^{d_{e'}}$	第 l 层边 (i,j) 的嵌入
$\mathbf{t}_{\text{emb}}$	向量	$\mathbb{R}^{d_v}$	时间嵌入
$\hat{\mathbf{v}}_i$	向量	$T_{\mathbf{x}_{t,i}}\mathcal{M}$	模型预测切向量
$\hat{\mathbf{P}}_{ij}^{(k)}$	标量	$[0,1]$	边类型概率预测
$\kappa^{(s)}$	函数	$\mathcal{M} \times \mathcal{M} \to \mathbb{R}$	第 s 头 Geodesic Kernel
$\hat{\rho}_i$	标量	$\mathbb{R}_{\geq 0}$	层级深度估计
$\odot$	运算	—	逐元素乘积（Hadamard 积）
$\|$	运算	—	向量拼接

流匹配

符号	类型	值域	含义
t	标量	$[0,1]$	流匹配时间步（0= 噪声，1= 数据）
$\mathbf{X}_0, \mathbf{E}_0$	—	—	噪声端采样
$\mathbf{X}_1, \mathbf{E}_1$	—	—	数据端（训练子图）
$\mathbf{x}_{t,i}$	向量	$\mathcal{M}$	节点 i 在时间 t 的插值坐标
$\mathbf{E}_{t,ij}$	向量	$\{0,1\}^K$	边 (i,j) 在时间 t 的插值类型
z_{ij}	标量	$\{0,1\}$	边插值掩码，$z_{ij} \sim \mathrm{Bernoulli}(t)$
$\mathbf{u}_{t,i}$	向量	$T_{\mathbf{x}_{t,i}}\mathcal{M}$	条件向量场目标
ρ_k	标量	$[0,1]$	关系 r_k 的边际频率
$p_0^{\mathcal{M}}$	分布	—	连续噪声先验
$R_{\mathbb{H}}$	标量	$\mathbb{R}_{>0}$	双曲均匀分布截断半径
σ_0	标量	$\mathbb{R}_{>0}$	欧氏噪声标准差
T	标量	$\mathbb{Z}_{>0}$	推理步数
Δt	标量	$(0,1]$	推理步长，$\Delta t = 1/T$
p_{flip}	函数	$[0,1]$	边更新翻转概率

损失函数

符号	类型	值域	含义
$\mathcal{L}_{\mathrm{cont}}$	标量	$\mathbb{R}_{\geq 0}$	流形向量场损失
$\mathcal{L}_{\mathrm{disc}}$	标量	$\mathbb{R}_{\geq 0}$	边类型损失
$\mathcal{L}_{\mathrm{align}}$	标量	$\mathbb{R}_{\geq 0}$	图-文对比损失
$\mathcal{L}$	标量	$\mathbb{R}_{\geq 0}$	总训练损失
λ, μ	标量	$\mathbb{R}_{>0}$	损失权重
τ	标量	$\mathbb{R}_{>0}$	对比损失温度
w_k^+	标量	$\mathbb{R}_{>0}$	关系 r_k 正样本权重
$w_{\max}$	标量	$\mathbb{R}_{>0}$	正样本权重截断上限
$\mathcal{S}$	集合	$\subseteq [N]^2$	边损失采样集
$\mathcal{B}$	集合	$\subseteq [N]$	对比损失 mini-batch 索引
$\epsilon_t, \epsilon_p, \epsilon_\kappa$	标量	$\mathbb{R}_{>0}$	数值稳定/截断常数

下游任务

符号	类型	值域	含义
$\mathbf{m}^{\text{task}}$	向量	$\{0,1\}^N$	节点任务掩码
$\mathbf{M}^{\text{task}}$	矩阵	$\{0,1\}^{N\times N}$	边任务掩码
$\mathcal{L}_{\text{cont}}^{\text{task}}, \mathcal{L}_{\text{disc}}^{\text{task}}$	标量	$\mathbb{R}_{\geq 0}$	条件化微调损失
$p_{\text{mask}}^{E}, p_{\text{mask}}^{V}$	标量	$(0,1)$	KGC 掩码概率
$\mathbf{c}_q$	向量	$\mathbb{R}^{d_c}$	T2G 查询文本嵌入
$S_{ij}^{(k)}$	标量	$[0,1]$	边异常分数
S_i	标量	$[0,1]$	节点异常分数
$\mathcal{T}$	集合	$\subset (0,1)$	GAD 预选时间步集
$\mathcal{N}_i$	集合	$\subseteq [N]$	节点 i 的出边邻居集
ϵ_{null}	标量	$\mathbb{R}_{>0}$	虚节点检测阈值
p_{thresh}	标量	$(0,1)$	边二值化阈值